

Baseline 对比与 $\Delta P^{0.5}$ Stage-3 MLP

Hiroyasu-Arai 、Naber-Siebers 、Sparse GP 与五 seed 外部 clean eval

Linan Jiang

Aalto University

9 May 2026

Frozen slide data snapshot: Thesis/generated/baseline_comparison_20260509/

这套 slides 的证据链

问题	方法	读法
物理公式能否解释数据？	Hiroyasu-Arai 与 Naber-Siebers	确定性物理相关式；给出强但刚性的 reference。
普通 ML baseline 是否已足够？	Sparse heteroscedastic GP	非参数、带不确定度；检验 MLP 是否只是吃到小数据优势。
神经网络是否稳定？	$\Delta P^{0.5}$ Stage-3, 5 seed	看 seed-to-seed 波动，而不是单次 run headline。
是否泛化到未见喷嘴？	Leave-one-nozzle-out	整组喷嘴从训练中移除，测试真正的 OOD 插值/外推压力。
不确定度是否可信？	Coverage、reliability、CRPS、PIT	区分“误差小”和“误差条有统计意义”。

本 deck 的重点不是只报一个 RMSE，而是把 accuracy、tail error、calibration、seed stability 与 OOD behaviour 放在同一协议框架下解释。

指标含义：accuracy、tail 与 calibration

点预测误差

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_i (\hat{y}_i - y_i)^2}, \quad \text{MAE} = \frac{1}{n} \sum_i |\hat{y}_i - y_i|.$$

RMSE 对大误差更敏感；MAE 更接近日常意义上的平均毫米误差。

$$\text{Bias} = \frac{1}{n} \sum_i (\hat{y}_i - y_i)$$

用于判断系统性高估或低估。

尾部误差与不确定度

$$P95 = \text{quantile}_{0.95}(|\hat{y} - y|)$$

表示 95% 点的误差不超过该值，直接反映 worst-case tail。

$$\text{Coverage}_{k\sigma} = \Pr(|y - \mu| \leq k\sigma).$$

若 Gaussian 预测校准良好， $1\sigma/2\sigma$ 应接近 0.683/0.954。高于 nominal 是 over-coverage，通常更保守但不够 sharp。

协议含义：in-pipeline vs external clean

In-pipeline 5-seed bootstrap

每个 seed 完整重跑 Stage-1/2/3 pipeline，并在该 seed 的 post-evaluation test subset 上计算 winner metrics。Bootstrap 的对象是 seed-level metric：对五个 seed 有放回重采样，得到均值的经验分布与 95% interval。它回答的是：训练随机性会不会改变结论？

External clean protocol

训练好的模型再统一评估到同一个 full-clean diagnostic set：795 561 points，33 845 trajectories。它回答的是：所有方法在同一大规模外部 clean 集合上谁更准？

严谨表述

这两个协议不能直接混合成一个数字。本文把 in-pipeline 结果用于 seed stability，把 external clean 结果用于 headline model comparison。

一句话结论

同一外部 clean eval 协议

$\Delta P^{0.5}$ 特征工程后的 Stage-3 MLP 五 seed 均值，在 795 561 个点、33 845 条轨迹上达到 **RMSE 6.211 mm $\pm$ 0.283 mm**。

相对物理 baseline

- vs Hiroyasu–Arai : RMSE **-37.7%** , MAE **-40.3%** 。
- vs Naber–Siebers : RMSE **-29.7%** , MAE **-32.3%** 。
- vs sparse GP : RMSE **-10.0%** , MAE **-11.9%** 。

相对旧 MLP

- 旧 $\Delta P^{0.25}$ seed 42 : RMSE 6.696 mm 。
- 新 $\Delta P^{0.5}$ 五 seed 均值 : RMSE 6.211 mm 。
- Sparse GP mean : RMSE 6.898 mm , MAE 5.206 mm 。

Headline 对比表

Model	RMSE	MAE	Bias	P95	1σ cov.	2σ cov.
Hiroyasu-Arai calibrated	9.974	7.686	+0.625	20.493	0.536	0.886
Naber-Siebers delay	8.840	6.780	-0.344	17.922	0.620	0.893
Stage-3 MLP $\Delta P^{0.25}$, seed 42	6.696	4.875	-1.149	14.118	0.745	0.979
Stage-3 MLP $\Delta P^{0.5}$, 5-seed mean	6.211	4.587	-0.838	13.029	0.774	0.981
Sparse heteroscedastic GP, 5-seed mean	6.898	5.206	-1.184	14.365	0.670	0.950

写进 thesis 时的定位

旧 MLP 结果不再作为神经网络 headline，只作为 ΔP 指数从 0.25 改到 0.5 之前的 reference row。
GP 是强 ML baseline：校准接近 nominal，但精度不及新 MLP 五 seed 均值。

Source: snapshot/headline_comparison.csv

理论角色

Hiroyasu–Arai 把喷雾穿深写成分阶段经验律：早期受喷出速度控制，破碎后转入 entrainment-dominated 的平方根时间标度。Zhou 型后喷射扩展进一步给出 EOI 后 $(t - t_i)^{1/4}$ 分支。

$$S(t) = \begin{cases} k_v \sqrt{2\Delta P / \rho_l} t, & t < t_b, \\ k_p (\Delta P / \rho_a)^{1/4} d_n^{1/2} t^{1/2}, & t \geq t_b. \end{cases}$$

$$t_b = k_{bt} \frac{\rho_l d_n}{\sqrt{\rho_a \Delta P}}, \quad S_{\text{post}} \propto (\Delta P / \rho_a)^{1/4} d_n^{1/2} t_i^{1/4} (t - t_i)^{1/4}.$$

本研究使用 calibrated 版本作为强物理 baseline；其 uncertainty 来自残差统计，不是输入相关的 learned $\sigma(x, t)$ 。

理论角色

Naber-Siebers 是 mixing-limited penetration 相关式。它把主要工况依赖折叠进物理尺度 A ，再乘以 $\sqrt{t}$ 型时间增长。

$$S(t) = K \underbrace{\left(\frac{\Delta P}{\rho_a} \right)^{1/4} d_n^{1/2}}_{A_{\text{NS}}} \sqrt{\max(t - t_d, 0)}.$$

- K : global scale ; t_d : 液压/观测延迟。
- optional cone-angle variant 可使用 video-measured θ ，但 headline 对比使用无需 oracle visual feature 的 delay variant。
- 方法意义：给 MLP 一个可解释、低自由度、物理刚性的 baseline。

GP 学习目标：从 MLP 回归换一个先验

先把问题写成和 MLP 一样的监督学习

每个样本点是

$$x_i = [t, \text{tilt}, \text{plumes}, t_{\text{inj}}, p_{\text{ctrl}}]_i, \quad z_i = \frac{S_i}{A_i}.$$

其中

$$A_i = (\Delta P_i)^{0.5} \rho_{a,i}^{-0.25} d_{n,i}^{0.5}.$$

MLP 学的是 $x \mapsto z$ 。GP baseline 也学同一个目标，最后再乘回 A_i 得到 mm。

区别只在函数假设

MLP：用参数 θ 显式表示函数 $z_\theta(x)$ 。

GP：不先写一个固定网络，而是直接在函数 $f(x)$ 上放概率先验：

$$z_i = f(x_i) + \epsilon_i.$$

GP 定义：不是一条曲线，而是一族联合 Gaussian

有限维定义

若任意有限输入集合 $X = [x_1, \dots, x_n]$ 上的函数值都满足

$$\mathbf{f}_X = [f(x_1), \dots, f(x_n)]^\top \sim \mathcal{N}(\mathbf{m}_X, K_{XX}),$$

则称

$$f(x) \sim \mathcal{GP}(m(x), k(x, x')).$$

mean function

$$(\mathbf{m}_X)_i = m(x_i)$$

本实现使用 constant mean，让数据学习整体 offset。

kernel / covariance

$$(K_{XX})_{ij} = k(x_i, x_j)$$

kernel 决定“两个输入点的函数值应该多相似”。

Kernel：本论文用 ARD Matérn-5/2

距离不是普通欧氏距离，而是按特征维度缩放

$$r^2(x, x') = \sum_{j=1}^5 \left(\frac{x_j - x'_j}{\ell_j} \right)^2.$$

ℓ_j 是第 j 个输入维度的 length-scale。若 ℓ_j 大，函数对该维度不敏感；若 ℓ_j 小，该维度的小变化也会让预测变化。

Matérn-5/2 covariance

$$k_\theta(x, x') = \sigma_f^2 \left(1 + \sqrt{5}r + \frac{5r^2}{3} \right) \exp(-\sqrt{5}r).$$

它比 RBF 少一点“过度光滑”的假设，适合喷雾穿深这种平滑但带瞬态变化的函数。

代码对应：`ScaleKernel(MaternalKernel(nu=2.5, ard_num_dims=5))`。

Exact GP 推导：训练点和测试点联合 Gaussian

同方差观测噪声版本，先看最基本公式

$$\mathbf{z} = \mathbf{f}_X + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \sigma_n^2 I).$$

对测试点 $\mathbf{x}_*$ ，联合分布为

$$\begin{bmatrix} \mathbf{z} \\ \mathbf{f}_* \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{m}_X \\ \mathbf{m}_* \end{bmatrix}, \begin{bmatrix} K_{XX} + \sigma_n^2 I & K_{X*} \\ K_{*X} & K_{**} \end{bmatrix} \right).$$

条件 Gaussian 公式就是 GP 预测公式

$$\begin{aligned} \mu_* &= \mathbf{m}_* + K_{*X}(K_{XX} + \sigma_n^2 I)^{-1}(\mathbf{z} - \mathbf{m}_X), \\ \Sigma_* &= K_{**} - K_{*X}(K_{XX} + \sigma_n^2 I)^{-1}K_{X*}. \end{aligned}$$

这两行就是“根据相似训练点加权平均，并给出不确定度”。

Exact GP 为什么不能直接用在本数据上？

超参数学习来自 marginal likelihood

令 $K_y = K_{xx} + \sigma_n^2 I$ ，则

$$\log p(\mathbf{z}|\mathbf{X}, \theta) = -\frac{1}{2}(\mathbf{z} - \mathbf{m})^\top K_y^{-1}(\mathbf{z} - \mathbf{m}) - \frac{1}{2} \log |K_y| - \frac{n}{2} \log 2\pi.$$

第一项奖励拟合，第二项惩罚过复杂 covariance，第三项是常数。

瓶颈

要算 $K_y^{-1}\mathbf{z}$ 和 $\log |K_y|$ ，通常需要 Cholesky 分解：

$$K_y = LL^\top, \quad \text{cost} = O(n^3), \quad \text{memory} = O(n^2).$$

本任务把每条轨迹展开成大量 time points；每个 seed 训练点可到百万级。因此 exact GP 不可行，必须用 sparse variational GP。

Sparse GP : 用 inducing points 压缩函数信息

核心想法

选择 $m \ll n$ 个 inducing inputs

$$Z = [z_1^{(u)}, \dots, z_m^{(u)}], \quad \mathbf{u} = f(Z).$$

它们不是训练标签，而是函数的“支撑点”。训练时学习这些点附近的函数分布，再用它们解释所有 n 个训练样本。

条件结构

GP 先验给出

$$p(\mathbf{f}, \mathbf{u}) = p(\mathbf{f}|\mathbf{u})p(\mathbf{u}), \quad p(\mathbf{u}) = \mathcal{N}(\mathbf{m}_Z, K_{ZZ}).$$

若 $m = 256$ ，主要矩阵操作从 $n \times n$ 变成围绕 $m \times m$ 与 minibatch covariance 展开。

本实现用 K-means 在训练输入中初始化 256 个 inducing points，并允许其位置继续学习。

Variational GP : 把后验 $p(\mathbf{u}|\mathcal{D})$ 换成可优化的 $q(\mathbf{u})$

变分分布

Exact posterior $p(\mathbf{u}|\mathcal{D})$ 难直接算，因此设

$$q(\mathbf{u}) = \mathcal{N}(\mathbf{m}_u, S_u),$$

其中 $\mathbf{m}_u$ 和 S_u 是待优化参数。对任意训练点函数值：

$$q(\mathbf{f}) = \int p(\mathbf{f}|\mathbf{u})q(\mathbf{u}) d\mathbf{u}.$$

ELBO : 优化一个可算的下界

$$\mathcal{L} = \sum_{i=1}^n \mathbb{E}_{q(\mathbf{f}_i)} [\log p(\mathbf{z}_i|\mathbf{f}_i)] - \text{KL}(q(\mathbf{u}) \parallel p(\mathbf{u})).$$

第一项要求预测能解释数据；第二项防止 $q(\mathbf{u})$ 偏离 GP 先验太远。Minibatch 训练时，把 batch 的 likelihood 项按 $n/|\mathcal{B}|$ 缩放。

本论文的 heteroscedastic GP : 两个 SVGP 串起来

第一阶段 : mean SVGP

$$f_{\mu}(x) \sim \mathcal{GP}(m_{\mu}, k_{\mu}), \quad z_i = f_{\mu}(x_i) + \epsilon_i.$$

训练后得到

$$\hat{\mu}_z(x) = \mathbb{E}[f_{\mu}(x)].$$

第二阶段 : log-variance SVGP

先用 mean GP 在训练集上算 residual :

$$r_i = z_i - \hat{\mu}_z(x_i).$$

再构造 variance target :

$$g_i = \log(r_i^2 + \varepsilon).$$

第二个 SVGP 学

$$f_v(x) \approx g, \quad \hat{\sigma}_z^2(x) = \exp(\hat{f}_v(x) + b).$$

b 是 validation 上的 log-variance bias correction °

从 scaled GP 回到论文里的 mm 预测

scaled space

GP 训练和预测都在

$$z = \frac{S}{A_{\text{scale}}}$$

空间进行，所以输出是

$$\hat{\mu}_z(x), \quad \hat{\sigma}_z(x).$$

physical space

回到穿深单位：

$$\hat{\mu}_S(x) = A_{\text{scale}}(x)\hat{\mu}_z(x), \quad \hat{\sigma}_S(x) = A_{\text{scale}}(x)\hat{\sigma}_z(x).$$

评价 RMSE、MAE、P95、coverage 时全部使用 $\hat{\mu}_S, \hat{\sigma}_S$ 与真实 S 的 mm 值。

一个实现细节

本次 headline GP 使用 residual log-variance 作为主要 uncertainty ; `include_mean_posterior_var=false` . 也就是不额外把 mean GP 的 posterior variance 加进 σ 。

把公式映射到本项目代码

数学对象	本实现	解释
x	a_only features	time、tilt、plume count、injection duration、control backpressure。
$z = S/A$	target_scaled	和 Stage-3 MLP 使用同一 $\Delta P^{0.5}$ scale。
k_θ	ARD Matérn-5/2	每个输入维度一个 length-scale。
$Z, \mathbf{u}$	256 inducing points	K-means 初始化，训练时位置可学习。
$q(u)$	Cholesky variational distribution	GPyTorch 的 sparse variational posterior。
$\mathcal{L}$	VariationalELBO	minibatch Adam，mean 与 logvar 各训练最多 80 epoch。
$\sigma(x)$	second SVGP on $\log r^2$	two-stage heteroscedastic uncertainty。

代码入口：MLP/MLP_training/run_gp_baseline.py

为什么这个 GP baseline 是公平但仍输给 MLP ?

公平性

GP 使用与 MLP 相同的 split、相同的 five seeds、相同的 A_{scale} target、相同的 controllable input features，并在同一个 external clean diagnostic set 上评价。

GP 的优势

Kernel prior 给出强平滑假设，SVGP 自带概率预测，two-stage logvar 让不确定度随输入变化。所以它不是弱 baseline；它确实把 coverage 拉到接近 nominal。

MLP 的优势

Stage-3 MLP 不只是普通回归器：它继承 fitted target 的完整轨迹结构，又在早期可靠区间对 raw CDF 做细化。GP baseline 学同一批 pointwise targets，但没有这一套 teacher/raw 分段训练机制。

GP 能打赢 MLP 吗？

Accuracy : 没有

Metric	MLP	GP
RMSE	6.211	6.898
MAE	4.587	5.206
P95	13.029	14.365

相对新 MLP，GP 的 RMSE/MAE/P95 分别高 11.1%/13.5%/10.2%。

Calibration : GP 更接近 nominal

Metric	MLP	GP
1σ cov.	0.774	0.670
2σ cov.	0.981	0.950

Gaussian nominal 为 0.683/0.954。GP 的不确定性更贴近 nominal，MLP 在 clean set 上偏保守。

结论

GP 是强 baseline，尤其证明 uncertainty comparison 是公平的；但在同一 external clean 协议下，它没有打赢 $\Delta P^{0.5}$ Stage-3 MLP。

OOD / LONO : 方法含义

Leave-one-nozzle-out protocol

LONO 将某个 nozzle family / experiment label 的全部样本从训练集中移除，只在该 held-out group 上测试。它比普通 group-aware split 更严格，因为测试喷嘴在训练阶段完全不可见。


它回答的问题

External clean eval 主要验证同分布条件下的性能；LONO 验证模型能否在未见喷嘴族上保持物理 scaling 与 residual learning 的有效性。这里的统计对象是 fold-to-fold variation，而不是 seed-to-seed variation。

当前 5-fold 结果

MLP $\Delta P^{0.5}$: RMSE 7.435 ± 0.692 mm ; HA : 10.713 ± 1.542 mm ; NS : 9.784 ± 2.102 mm 。相对 HA/NS 的 RMSE 下降约 30.6% / 24.0% 。


LONO 结果：每个 held-out nozzle 的 RMSE



五个 held-out fold 中，MLP 均低于 HA 与 NS；最难 fold 为 BC20241017_HZ_Nozzle2，MLP RMSE 为 8.517 mm，仍低于 HA 11.754 mm 与 NS 11.236 mm。

Source: MLP/runs_mlp/lono_pipeline_20260509_215613/per_fold.csv


LONO 结果：coverage 是否随 OOD 崩掉？



MLP 的 1σ coverage 均值为 0.701，接近 Gaussian nominal 0.683；Nozzle2 fold 明显偏 under-coverage，说明该喷嘴族仍是 OOD 风险点，而不是被平均值掩盖。

Source: MLP/runs_mlp/lono_pipeline_20260509_215613/aggregate.csv


误差指标：物理 baseline、GP 与 MLP



在该 clean 评估协议下，sparse GP 明显优于物理 baseline，但仍未超过 $\Delta P^{0.5}$ Stage-3 MLP 的 RMSE、MAE 和尾部 P95 error。

Source: snapshot/headline_comparison.csv


五 seed 外部评估：MLP vs GP



$\Delta P^{0.5}$ MLP 五 seed RMSE 均值为 6.211 mm；GP 五 seed external mean 为 6.898 mm。GP 的最好 seed 仍高于 MLP 的 5-seed mean。

Source: snapshot/new_mlp_5seed_aggregate.csv

Coverage : GP 更接近 nominal , MLP 更准



新 MLP 的 $1\sigma/2\sigma$ coverage 为 0.774/0.981 , 属于 clean set 上 over-coverage ; GP 为 0.670/0.950 , 更接近 Gaussian nominal 0.683/0.954 。 因此 GP 赢在 calibration closeness , MLP 赢在 accuracy 。

Source: snapshot/headline_comparison.csv

写入 thesis 的推荐表述

Abstract / introduction 版本

$\Delta P^{0.5}$ feature engineering reduced the Stage-3 MLP RMSE from 6.70 mm for the previous $\Delta P^{0.25}$ seed-42 model to 6.21 mm $\pm$ 0.28 mm over five full-clean external evaluations.

Results 版本

Under the same 795 561-point clean diagnostic protocol, the $\Delta P^{0.5}$ Stage-3 MLP reduced RMSE by 37.7% relative to the calibrated Hiroyasu–Arai correlation, by 29.7% relative to the Naber–Siebers delay model, and by 10.0% relative to a sparse heteroscedastic GP.

Source: snapshot/DATA_SOURCES.md

GP 与稳定性 caveat

GP baseline 版本

The sparse heteroscedastic GP reached near-nominal uncertainty coverage (0.670/0.950 for $1\sigma/2\sigma$), but its external-clean RMSE, MAE, and P95 error were 11.1%, 13.5%, and 10.2% higher than the $\Delta P^{0.5}$ Stage-3 MLP five-seed mean.

Limitations 版本

The five-seed aggregate is a $\Delta P^{0.5}$ Stage-3 pipeline aggregate, not a strict same-ablation seed study: seed 2024 selected `raw_reliable_no_kd`, whereas the other four seeds selected `anchor_off`.

Source: `snapshot/DATA_SOURCES.md`

数据来源与更新入口

Item	Path
Frozen snapshot	Thesis/generated/baseline_comparison_20260509/
Source report	MLP/baseline/comparison_reports/gp_vs_mlp_20260509/
Headline table	Thesis/generated/baseline_comparison_20260509/headline_comparison.csv
Five-seed aggregate	Thesis/generated/baseline_comparison_20260509/new_mlp_5seed_aggregate.csv
Per-seed eval rows	Thesis/generated/baseline_comparison_20260509/per_seed_new_mlp_eval.csv
GP bootstrap	Thesis/generated/baseline_comparison_20260509/gp_bootstrap_summary.json
LONO result	MLP/runs_mlp/lono_pipeline_20260509_215613/
Figure builder	Thesis/generated/baseline_comparison_20260509/make_figures.py

刷新流程

更新 comparison report 的 CSV → 覆盖本 snapshot 中的 CSV → 运行

.venv/Scripts/python.exe Thesis/generated/baseline_comparison_20260509/make_figures.py → 重编译本 slides。

协议标签

所有 headline rows 均为 external clean eval : 795 561 points · 33 845 trajectories。