

物理基线、Production MLP 与 SVGP 对比

2026-05-21 full-clean / uncensored CDF / P50-Q1 统一评估

Linan Jiang

Aalto University

21 May 2026

为什么更新这组 slides

旧版本的问题

旧 baseline deck 主要记录 5 月上旬的中间模型，且叙事重点是 MLP 相对早期 GP baseline 的提升。

现在的论文口径

最新比较使用同一批 2026-05-21 评估产物：production MLP 五 seed、mu-anchor/raw-uncertain 变体、Stage-3 SVGP、以及重新拟合的 Hiroyasu-Arai / Naber-Siebers。

一句话结论

Production MLP 显著优于 HA/NS 物理曲线基线；SVGP 在点预测 RMSE/MAE 上仍略领先；MLP 的优势是更保守的不确定度覆盖，适合作为 screening surrogate。

口径	点数	工况/轨迹	作用
Full-clean CDF	692 942	24 316 trajectories	主 headline；所有模型在同一 clean CDF 点集上比较。
Conservative uncensored CDF	542 565	592 conditions	排除保守判定的 FOV 右删失和信号衰减时间桶。
P50 observed	4213	495 conditions	按工况聚合后的 P50 观测点，检验均值头的稳健性。
Q1 extrapolated grid	21 527	495 conditions	P50/Q1 拟合外推区间；主要看 mu 头的外推趋势。

这些口径不是互相替代：full-clean 给整体 CDF 精度，uncensored CDF 控制删失偏差，P50/Q1 检查按工况压缩之后的稳健性和外推行为。

Source: [Thesis/generated/baseline_comparison_20260521/summary.json](#)

模型组

模型	设置
Hiroyasu–Arai calibrated Naber–Siebers delay Production MLP	在当前 clean 口径重新校准的经验曲线基线。 带 delay 处理的经验曲线基线，同样重新拟合。 Stage-3 anchor_off，seeds 7/17/42/99/2024，报告 mean $\pm$ std。
mu-anchor raw-uncertain prodKD Stage-3 SVGP	同数据、同 teacher 热启动的 mu-anchor/raw-uncertain/product KD 组合。 稀疏异方差 GP baseline，seed 42，吃同一 full-clean / fixed-table 评估数据。

公平比较边界

这里比较的是同数据评估口径，不把 production 模型直接和 LONO 结果混读。LONO 是泛化压力测试，已经拆到独立 stage-1/2/3 ablation decks。


Full-Clean Headline

模型	RMSE	MAE	Bias	P95	Cov1
Hiroyasu-Arai	11.268	8.658	+0.288	22.891	0.615
Naber-Siebers	10.545	8.177	-0.442	21.253	0.637
Production MLP mean(5)	4.735	3.293	+0.626	9.167	0.867
mu-anchor raw-uncertain	5.200	3.654	-0.585	10.525	0.834
SVGP Stage-3	4.628	3.173	-0.070	9.242	0.703

Production MLP 比 HA/NS 降低超过一半 RMSE，但 SVGP 仍是 full-clean 点预测精度冠军。MLP 的 $1\sigma/2\sigma$ coverage 明显更保守。


Source: Thesis/generated/baseline_comparison_20260521/headline_full_clean.csv

Full-Clean: Error Metrics




Source: Thesis/images/baseline_comparison_20260521/full_clean_metric_bars_rmse_mae_p95.png

Full-Clean: Coverage



Source: Thesis/images/baseline_comparison_20260521/full_clean_coverage_comparison.png

Production MLP 五 seed 稳定性



Full-clean aggregate

- $\text{RMSE} = 4.735 \text{ mm} \pm 0.037 \text{ mm}$
- $\text{MAE} = 3.293 \text{ mm} \pm 0.039 \text{ mm}$
- $\text{Bias} = +0.626 \text{ mm} \pm 0.112 \text{ mm}$
- $\text{Cov1/Cov2} = 0.867/0.985$

读法

这不是 seed luck : 五个 seed 的 RMSE spread 只有约 0.04 mm °

Source: Thesis/generated/baseline_comparison_20260521/production_mlp_full_clean_per_seed.csv



Conservative Uncensored CDF

模型	RMSE	MAE	Bias	P95	Cov1
Hiroyasu-Arai	10.261	7.767	+2.152	21.095	0.630
Naber-Siebers	9.286	7.195	+0.628	18.408	0.659
Production MLP mean(5)	4.265	3.032	+0.562	8.307	0.887
mu-anchor raw-uncertain	4.941	3.505	-0.868	10.123	0.840
SVGP Stage-3	4.193	2.894	-0.040	8.461	0.716

删失保守过滤后，production MLP 和 SVGP 的点误差仍非常接近；SVGP RMSE 略低，MLP coverage 更宽。

Source: Thesis/generated/baseline_comparison_20260521/fixed_table_group_summary.csv

Uncensored CDF: Error and Coverage



Source: Thesis/images/baseline_comparison_20260521/cdf_uncensored_*.png



P50 与 Q1 口径

模型	P50 RMSE	P50 MAE	Q1 extrap. RMSE	Q1 extrap. MAE
Q1 oracle	1.010	0.689	—	—
Hiroyasu–Arai	9.948	7.662	31.837	25.316
Naber–Siebers	9.048	7.206	39.818	32.216
Production MLP mean(5)	2.848	1.826	10.864	7.380
mu-anchor raw-uncertain	3.212	2.147	10.358	6.965
SVGP Stage-3	2.649	1.603	10.591	7.236

P50 observed 上 SVGP 最好；Q1 extrapolated 上 mu-anchor 组合略有帮助，但这不是 full-clean 主模型的胜利，只说明 mu 头对外推网格有局部价值。

Source: [Thesis/generated/baseline_comparison_20260521/fixed_table_group_summary.csv](#)

P50 Observed 与 Q1 Extrapolated



Source: Thesis/images/baseline_comparison_20260521/p50_observed_*.png;q1_extrapolated_*.png

- ① 不说 MLP 已经超过 SVGP；最新实验证据不支持这个强表述。
- ② 可以说 production MLP 在所有 clean / uncensored / P50 口径下都远强于 HA/NS。
- ③ 可以说 SVGP 在点预测上略优，尤其 RMSE/MAE；这是公平的 ML baseline。
- ④ 可以强调 MLP 的 coverage 更保守，适合 downstream screening 和安全余量估计。
- ⑤ 可以把 mu-anchor/raw-uncertain 放到 Q1 extrapolation 的补充结果里，而不是主 headline。

内容	路径
Slides source	Thesis/slides/baseline_comparison_slides_zh/baseline_comparison_slides_zh.tex
Figures	Thesis/images/baseline_comparison_20260521/
Generated tables	Thesis/generated/baseline_comparison_20260521/
Fixed-table report	MLP/baseline/comparison_reports/stage3_fixed_table_eval_with_hans_20260521/
Full-clean MLP vs SVGP	MLP/baseline/comparison_reports/mlp_production_stage3_vs_svgp_stage3_full_clean_20260521/
Figure script	Thesis/generated/baseline_comparison_20260521/make_figures.py